



Fehler Arten:


- Systematische Fehler (Bias): Messungen verhalten sich konstant falsch, aber immer gleich, keine grosse Streuung.
- Statistischer Fehler (Rauschen): Messungen sind unvorhersagbar falsch, manchmal zu gross, manchmal zu klein.

Was ist besser:

- Bekannter Systematischer Fehler — OK
- Unbekannter Systematischer Fehler — No Bueno, kann kompliziert werden
- Statistischer Fehler — Macht einzelne Messungen kaputt, aber kann durch grosse mengen kompensiert werden.

Fehler des Mittelwert:	$\Delta \bar{x} = \frac{\sigma}{\sqrt{N}}$
------------------------	--

Arten Verteilungen:



Verteilung	Parameter	Erwartungswert $E(X)$	Standartabweichung σ
Poisson	λ	λ	$\sqrt{\lambda}$
Binomial	n, p	np	$\sqrt{np(1-p)}$
Normal	μ, σ	μ	σ
Exponential	λ	$1/\lambda$	$1/\lambda$
Gleichverteilung $[a, b]$	a, b	$(a + b)/2$	$\frac{b - a}{\sqrt{12}}$

Momente von Verteilungen:

M0 (0. Moment)	1	1	-
M1 (1. Moment)	Mittelwert	$\frac{1}{n} \sum x_i$	-

~M4 (4. zentrales Moment)	Wölbung / Heavy tails	$\frac{1}{n} \sum (x_i - \bar{x})^4$	Klein: wenige Ausreisser Gross: viele Ausreisser
---------------------------	-----------------------	--------------------------------------	---

Runden:

1.284975 ± 0.037853	1.28 ± 0.04
633.287657 ± 0.937563	633.3 ± 0.9
$587.8763748 \pm 0.08137756$	587.88 ± 0.08
$23.1897645 \pm 1.72179654$	23 ± 2

$$\text{Rauschvarianz: } \sigma_z = \frac{\sqrt{\sigma_U^2 - \sigma_b^2}}{\text{Bias}} = \frac{\sqrt{\sigma_U^2 - \sigma_u^2}}{\text{Umwandlung}}$$

$$\text{Likelihood Funktion: } L(\lambda) = P(x | \lambda) P(y | \lambda) = \frac{e^{-\lambda} \lambda^x}{x!} \frac{e^{-\lambda} \lambda^y}{y!} = \frac{e^{-2\lambda} \lambda^{x+y}}{x! y!}.$$

$$\text{And: } \left(L_A = \prod_{i=1}^5 p_A(k_i) \right) \wedge \left(L_B = \prod_{i=1}^5 p_B(k_i) \right) \text{ Höheres likelihood} \rightarrow \text{wahrscheinlichste}$$

Vorhersage

$$\text{Poisson Verteilung: } P(X = k) = e^{-\mu} \frac{\mu^k}{k!}$$

$$\text{Poisson: } \sigma^2 = \mu \rightarrow \sqrt{\mu} = \sigma$$

$$\text{Satz von Bayes: } P(\text{krank} | +) = \frac{P(+ | \text{krank})P(\text{krank})}{P(+ | \text{krank})P(\text{krank}) + P(+ | \text{gesund})P(\text{gesund})}$$

Fehlerfortpflanzung:

$$\sigma_f^2 = \left(\frac{\partial f}{\partial a} \sigma_a \right)^2 + \left(\frac{\partial f}{\partial b} \sigma_b \right)^2 + \left(\frac{\partial f}{\partial c} \sigma_c \right)^2$$

Mit covarianz von b und c:

$$\sigma_f^2 = \left(\frac{\partial f}{\partial a} \sigma_a \right)^2 + \left(\frac{\partial f}{\partial b} \sigma_b \right)^2 + \left(\frac{\partial f}{\partial c} \sigma_c \right)^2 + 2 \frac{\partial f}{\partial b} \frac{\partial f}{\partial c} \text{cov}(b, c).$$

Alle korellieren:

$$\begin{aligned} \sigma_f^2 = & \left(\frac{\partial f}{\partial a} \sigma_a \right)^2 + \left(\frac{\partial f}{\partial b} \sigma_b \right)^2 + \left(\frac{\partial f}{\partial c} \sigma_c \right)^2 + \left(\frac{\partial f}{\partial d} \sigma_d \right)^2 \\ & + 2 \frac{\partial f}{\partial a} \frac{\partial f}{\partial b} \text{cov}(a, b) + 2 \frac{\partial f}{\partial a} \frac{\partial f}{\partial c} \text{cov}(a, c) + 2 \frac{\partial f}{\partial a} \frac{\partial f}{\partial d} \text{cov}(a, d) \\ & + 2 \frac{\partial f}{\partial b} \frac{\partial f}{\partial c} \text{cov}(b, c) + 2 \frac{\partial f}{\partial b} \frac{\partial f}{\partial d} \text{cov}(b, d) + 2 \frac{\partial f}{\partial c} \frac{\partial f}{\partial d} \text{cov}(c, d). \end{aligned}$$

Mess auflösung	Sampeling rate	Nyquist-frequenz	Anzahl Messpunkte
$\Delta t_{\max} = \frac{1}{2f_{\max}}$	$f_s = \frac{1}{\Delta t}$	$f_{\max} = \frac{f_s}{2}$	$N = \frac{f_s}{\Delta f}$

PSD $\Leftrightarrow$ viel Varianz pro Hertz im Signal steckt $\rightarrow \sigma^2 = \int_0^{f_{\max}} S(f) df$

Regression; ridge regression weniger anfällig für overfitting

R^2 -Score — wie gut erklärt ein Regressionsmodell die Daten:

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

Interpretation:

- $R^2 = 1$: perfekte Vorhersage
- $R^2 = 0$: nichtbesser als immer den Mittelwert vorherzusagen
- $R^2 < 0$: schlechter als immer den Mittelwert zu nehmen

Machine Learning:

ReLU	Standard für hidden Layers
Sigmoid	Ausgabe einer Wahrscheinlichkeit (0-1)
Softmax	Ausgabe mehrerer Klassen (Hund, Katze, Fisch)
Linear (Identität)	Regression (Alter, Temperatur, Preis)

Unsupervised Learning:

- Du hast Daten mit vielen Variablen (z. B. 100 Merkmale).
- PCA sucht die Richtungen, in denen die Daten am stärksten variieren.
- Dann projiziert sie die Daten auf diese Richtungen und reduziert so die Dimension.

Die erste Hauptkomponente (PC1) ist:

- der Eigenvektor zum größten Eigenwert der Kovarianzmatrix,
- also die Richtung mit der größten Varianz.

Die zweite Hauptkomponente (PC2):

- ist orthogonal zu PC1,
- hat die zweitgrößte Varianz.

Short:

- PCA = Dimensionsreduktion
- größter Eigenwert — erste Hauptkomponente
- kleinster Eigenwert — letzte Hauptkomponente

Some nice stuff (might definitely become usefull lol):

$$\frac{1}{f} = \frac{1}{g} + \frac{1}{b} \Leftrightarrow f = \frac{gb}{g+b} \Leftrightarrow \left(\frac{\partial f}{\partial g} = \frac{b^2}{(g+b)^2} \right) \wedge \left(\frac{\partial f}{\partial b} = \frac{g^2}{(g+b)^2} \right) \Leftrightarrow \Delta f = \sqrt{\left(\frac{b^2}{(g+b)^2} \Delta g \right)^2 + \left(\frac{g^2}{(g+b)^2} \Delta b \right)^2}$$

$$g = \frac{4\pi^2 l}{T^2} \Leftrightarrow \Delta g = g \sqrt{\left(\frac{\Delta l}{l} \right)^2 + \left(2 \frac{\Delta T}{T} \right)^2}$$

$$\rho = \frac{m}{\pi r^2 h} \iff \Delta \rho = \rho \sqrt{\left(\frac{\Delta m}{m}\right)^2 + \left(2\frac{\Delta r}{r}\right)^2 + \left(\frac{\Delta h}{h}\right)^2}$$

$$R = \left(\frac{n_1 - n_2}{n_1 + n_2}\right)^2 \iff \Delta R = \sqrt{\left(\frac{4n_2(n_1 - n_2)}{(n_1 + n_2)^3} \Delta n_1\right)^2 + \left(\frac{4n_1(n_1 - n_2)}{(n_1 + n_2)^3} \Delta n_2\right)^2}$$

$$\rho = \frac{\pi U d^2}{4 I L} \iff \Delta \rho = \rho \sqrt{\left(\frac{\Delta U}{U}\right)^2 + \left(2\frac{\Delta d}{d}\right)^2 + \left(\frac{\Delta I}{I}\right)^2 + \left(\frac{\Delta L}{L}\right)^2}$$

$$\text{Dosis} = \frac{\mu}{A}$$

$$\text{Max pooling } 2 \times 2 \text{ on } 7 \times 7 \text{ grösse: } \left\lfloor \frac{7-2}{2} \right\rfloor + 1 = \lfloor 2.5 \rfloor + 1 = 3$$